📊 拼多多春季消费分析项目 · 全过程复盘

文档信息

- 项目名称：拼多多春季消费分析——南昌 vs 深圳双城对比
- 时间跨度：2026年4月1日 - 4月21日
- 作者：李鑫
- 最新更新：2026年4月21日

一、项目背景：为什么要做这个？

完成第一个个人财务分析项目后，我发现自己用的技术栈是 **Excel + PowerBI**，但数据分析师岗位也一样常要求 **MySQL + Python + Tableau**。

于是我想：能不能做一个项目，把这三个工具都用上？

正好那段时间在用拼多多买东西，发现平台的价格和社交裂变特征很有意思。再加上我马上要去南昌实习，未来打算去深圳工作——**如果做一个南昌 vs 深圳的双城消费对比，是不是既有地域特色，又能体现商业分析能力？**

就这样，项目方向定了：**拼多多 + 春季 + 双城对比。**

二、第一阶段：数据生成（没有数据集，就自己造）

2.1 卡住的第一个问题：没有合适的数据集

我搜遍了 Kaggle 和阿里云天池，拼多多公开数据集非常少。淘宝的数据倒是多，但时间太久（2014年），而且没有城市字段。

怎么办？

我决定：**自己生成一个模拟数据集。**

2.2 让数据“真实”：基于官方报告的逻辑设计

不是随便编。我查了拼多多 2025-2026 年的消费报告，提炼出几个核心规律：

特征	数据来源	生成逻辑
女性用户占比约62%	悦己消费趋势	用户表性别比例 女:男 ≈ 6:4
90后00后订单量占51%	年龄结构报告	18-30岁用户占60%
58%订单在18-24点	消费时段分布	晚6-12点订单权重设为4倍
拼团订单占40%左右	社交裂变特征	is_group_order = 40%概率
价格敏感度高	下沉市场特征	设置促销、优惠券、价格带分析维度

2.3 刻意制造“脏数据”

为了让项目更贴近真实业务，我在生成数据时故意加入了各种脏数据：

- **空值**：5-8% 的用户城市、年龄、手机号为空
- **异常值**：价格为负数、年龄200岁、订单时间为2027年
- **格式错误**：日期格式混乱、手机号含字母
- **重复数据**：2% 的订单重复记录
- **逻辑错误**：拼团订单但分享次数为0

为什么这么做？ 因为真实工作中，数据永远不会是干净的。面试官想看到的是：**你发现问题、处理问题的能力。**

三、第二阶段：Python 数据清洗（把脏数据变干净）

3.1 清洗目标

把生成的三张表（users、products、orders）清洗成可以导入 MySQL 的干净数据。

3.2 主要清洗操作

表	问题	处理方式
users	city 为空	填充“未知”
users	age 为负数或 >100	删除异常值，中位数填充空值
users	日期格式错误	正则匹配，无法解析则删除
products	price 为负或0	删除，按品类中位数填充空值
products	rating >5 或 <1	删除，用中位数填充
orders	quantity 为负	删除，空值填充为1
orders	拼团但 share_count=0	修正为1

3.3 遇到的困难与解决

困难1：手机号格式五花八门

- 有的带空格、有的带横线、有的只有6位
- 解决：用正则表达式 `re.sub(r'\D', '', phone)` 提取数字，再判断是否为11位且以1开头

困难2：订单表清洗后行数大幅减少

- 从 9880 行 → 7207 行（删除了约27%的脏数据）
- 这说明模拟的脏数据比例是合理的，真实业务中数据质量可能更差

四、第三阶段：MySQL 深度分析（让数据说话）

4.1 先建表、导数据

在 MySQL Workbench 中创建 `pdd_analysis` 数据库，建立 users、products、orders 三张表，用 Python 脚本导入清洗后的 CSV。

导入脚本关键代码：

代码块

```
from sqlalchemy import create_engine
engine = create_engine('mysql+pymysql://root:password@localhost:3306/pdd_analysis')
users.to_sql('users', engine, if_exists='replace', index=False)
```

4.2 编写 8 个核心查询

我写了 8 个 SQL 查询，覆盖：

1. 双城消费画像（总消费、订单数、客单价）
2. 品类偏好对比（TOP5 品类及占比）
3. 价格带分析（0-50/50-100/100+ 分布）
4. 促销敏感度（优惠券使用率 vs 折扣率）
5. 社交裂变（拼团占比、平均分享次数）
6. 时间趋势（周度消费变化）
7. 用户分层（高/中/低价值用户）
8. 关联购买（品类组合分析）

4.3 遇到的困难与解决

困难1：MySQL 版本不支持 PERCENTILE_CONT

- 报错：`Error Code: 1064`
- 解决：改用 `NTILE(4)` 函数实现用户分层

困难2：订单表缺少 `is_promotion` 字段

- 原设计失误
- 解决：用 `coupon_discount > 0` 判断是否使用促销

困难3：关联购买查询没有数据

- 原因：order_time 精确到秒，同一用户同一秒买多个商品的概率极低
- 解决：改用 `DATE(order_time)` 同一天关联

五、第四阶段：Tableau 可视化（把洞察变成图表）

5.1 设计思路

核心原则：所有图表都要突出“南昌 vs 深圳”双城对比。

配色方案：

- 南昌：**青绿色**（#2E8B57）——代表南昌的绿水青山
- 深圳：**暖橙色**（#FF8C42）——代表深圳的创新活力

仪表盘结构（4个页面）：

页面	内容	图表类型
P1 执行摘要	核心KPI + 多维度对比	KPI卡片、雷达图
P2 深度对比	品类、价格带、促销敏感度	柱状图、堆叠条
P3 用户行为	用户分层 + 社交裂变	饼图、散点图
P4 时间趋势	周度消费趋势	双线折线图

5.2 遇到的困难与解决

困难1：Tableau Public 无法本地保存？

- 查资料发现新版已支持，放心了

困难2：不同工作表间颜色无法统一

- 手动为每个图表配置颜色，复制字段创建独立配色

困难3：KPI 卡片排版混乱

- 放弃固定容器，采用浮动布局 + 手动调整

困难4：如何导出高清 PDF？

- 发布到 Tableau Public → 浏览器打开 → 打印 → 另存为 PDF

5.3 最终成果

- 一个完整的 Tableau Public 在线仪表盘
- 4 张页面高清截图
- 一份可打印的 PDF 报告

在线链接：https://public.tableau.com/app/profile/xin.li8038/viz/17767007771270/P1

六、核心业务洞察（从数据中发现了什么？）

6.1 执行摘要

指标	南昌	深圳	差异
总消费额	127.5万	109.1万	南昌 +17%
订单数	3157	3329	深圳 +5%
客单价	404元	328元	南昌 +23%
人均消费	1256元	1263元	基本持平

结论：南昌用户“买得少但买得贵”，呈现“高质量、高客单”特征；深圳用户“买得多但买得便宜”，呈现“高频、活跃”特征。

6.2 品类偏好

- 服饰鞋帽是绝对主导品类（南昌70%，深圳60%）
- 美妆个护深圳（12%）高于南昌（9%），可能反映一线城市对形象管理的更高投入

6.3 价格带

- 50-100元是双城主力区间（均占约42%）
- 100元以上：南昌30% > 深圳27%，印证“南昌用户消费力更强”

6.4 促销敏感度

- 优惠券使用率：双城均超90%（深圳90.3% > 南昌90.1%）
- 折扣率：深圳10.25% > 南昌9.87%
- **结论**：深圳用户对促销更敏感，但差异很小，拼多多用户整体价格敏感度高

6.5 社交裂变

- 拼团率：双城高度一致（约39.5%）
- 平均分享次数：南昌2.76次，深圳2.75次
- **结论**：社交电商行为在两城没有显著差异，拼多多的裂变模式已全国普及

6.6 时间趋势

- 春季消费呈现“双峰”特征
- **高峰1：**3月中旬（周11-12），南昌春季大促，单周消费31万元
- **高峰2：**4月中旬（周15-16），深圳消费小高峰，达14.8万元
- 5月下旬双城同步回升，可能是五一促销效应

七、项目复盘：我学到了什么？

7.1 技术层面的成长

工具	之前	之后
MySQL	只会简单的 SELECT	能写窗口函数、CTE、复杂关联查询
Python	只会基础 pandas	能设计数据生成逻辑、处理脏数据、连接数据库
Tableau	没接触过	能独立完成专业仪表盘设计

7.2 思维层面的变化

1. **没有数据，就创造数据**：找不到合适的数据集时，不是放弃，而是思考“什么样的数据才合理”，然后自己生成。这个过程本身就是业务理解能力的体现。
2. **脏数据不是麻烦，是机会**：真实工作中数据永远是脏的。在项目中主动制造脏数据并清洗，面试时可以很自信地说：“我知道数据清洗有多重要，我有实战经验。”
3. **工具是为问题服务的**：这个项目用到了 MySQL、Python、Tableau 三个工具，但不是为了“堆砌技术栈”而用，而是每个工具都解决了特定阶段的问题。

7.3 如果重来一次，我会…

1. **更早规划 Tableau 的配色和布局**：后期调整花了不少时间
2. **在生成数据时增加更多时间维度**：比如“星期几”的字段，可以分析周末vs工作日
3. **先写 README 再做事**：第一个项目是先做完再写文档，这次项目过程中就记录了不少笔记

八、后续计划

这个项目暂时告一段落。接下来：

1. 上传到 GitHub，完成作品集
2. 开始准备第三个项目（业务分析方向）
3. 把这两个项目写到简历里，准备投实习

附：项目相关链接

- GitHub 仓库：https://github.com/wuxingzhu/pdd-spring-consumption-analysis
- Tableau 在线仪表盘：https://public.tableau.com/app/profile/xin.li8038/viz/17767007771270/P1